2026 Agentic AI on the Edge Hackathon | 智慧製造

實心胎
智慧製造戰情室

看得見每台機器、說得出異常原因、
排得出最有效率的生產與人力

以 NVIDIA DGX Spark 邊緣 AI Agent 打造資料不出廠、斷網照跑的工廠指揮中心

發現異常
1 分鐘
原本 2 小時巡檢一次

輪胎交期
−30%
13.3 → 9.3 週

大胎週產能
+63%
每台每週 3 → 4.9 顆

Team Westie

預期市場

全體	台灣橡膠製品業 **1,263 家**、營收 **NT$1,176 億**；全體導入潛力約 **NT$26 億**
可服務	批次硫化中小廠：多數沒有 MES，**不必先建 MES** 即可導入；已有 MES 的廠也能直接介接
首波	台灣實心胎廠（固滿德、昇達、三王、順進等）；零 MES 起步，可申請政府數位轉型補助（如經濟部 SBIR）

應用潛力

1 條線試點 → 全廠 28 台 → 同業
→ 輪胎、橡膠件、複合材料、熱處理
更換工具模組即可延伸至其他產業

一個畫面看見整座實心胎工廠：訂單、產線、機台、異常對策

實心胎智慧戰情室　**產線監控**　排程與人力　　● 正常 27 台　● 異常 1 台　10/22　14:26

① 訂單進度（完成／預計）

小胎	**38** / 100	剩餘約 208 小時
中胎	**12** / 100	剩餘約 1,241 小時
大胎	**8** / 100	剩餘約 2,162 小時

② 半成品進度（大胎 #07）

A 胎體／胎面膠	預熱中
B 胎側膠	成形中
C 鋼絲圈	包布中
D 尼龍布	已完成

③ 中央說明面板

異常：A 線大開煉機　溫度過高

膠溫 112°C 且持續上升（未加硫上限 120°C；已加硫另設 110°C 防焦燒）；原因：冷卻能力不足

溫度	壓力	時間	水流
112°C	正常	14 分	偏低

建議調整

✓ 已自動：通知維修冷卻水路

☐ 待核准：放慢生料投入　**核准**

排程影響：無，大胎 #07 仍 17:00 入硫化機

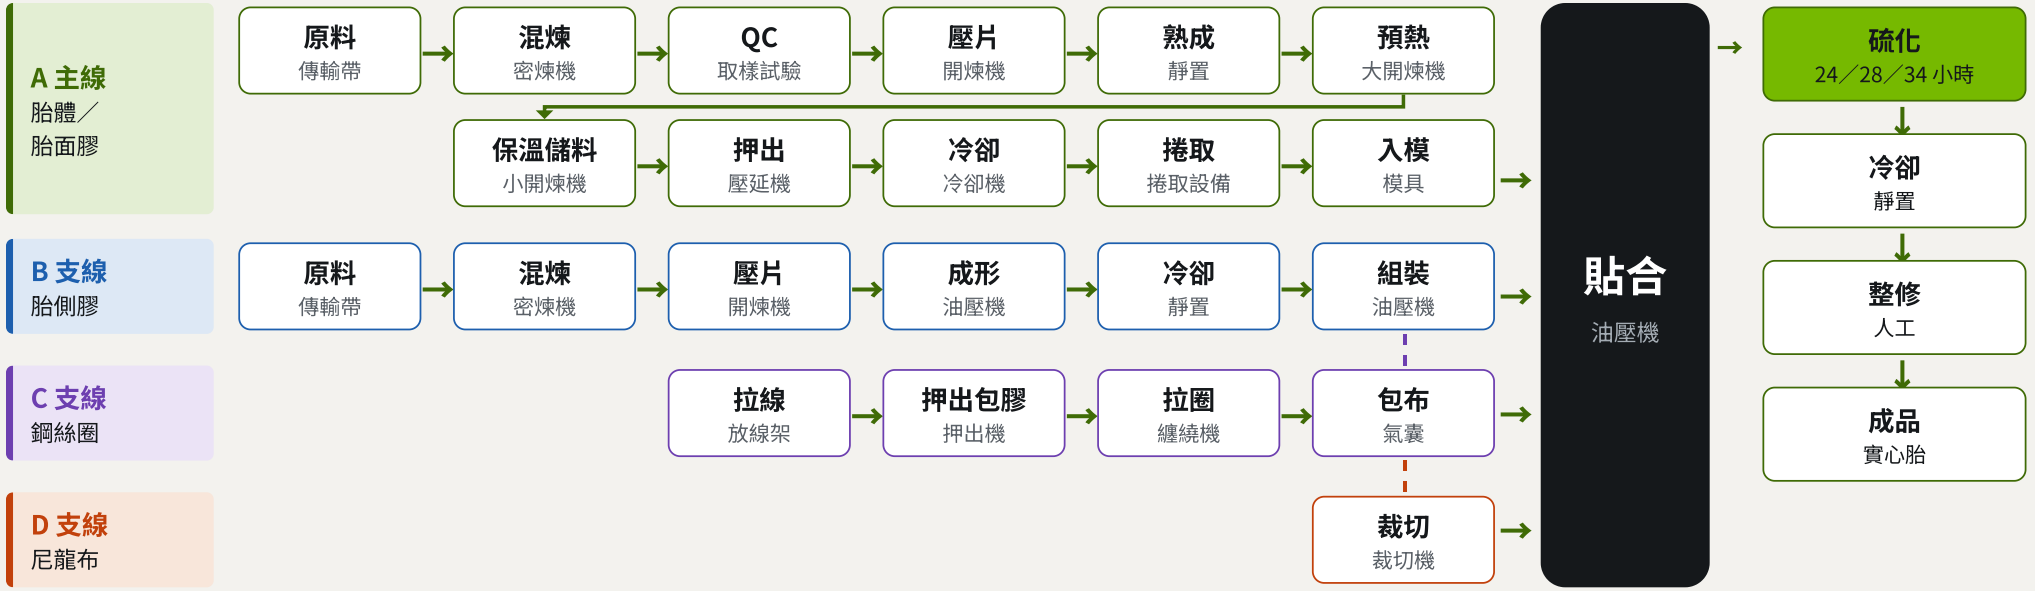
④ 機台狀態（依產線）

A	● 密煉 ● 開煉 ● 大開煉 ● 小開煉 ● 壓延 ● 冷卻 ● 捲取
B	● 密煉 ● 開煉 ● 成形 ● 組裝
C	● 放線 ● 押出 ● 纏繞 ● 包布
D	● 裁切
貼合	● 油壓
硫化	● 1 ● 2 ● 3 ● 4 ● 5 ● 6 ● 7 ● 8 ● 9 ● 10 ● 11

點選機台：看溫度、壓力、時間、水流

示意畫面；剩餘時間依硫化機產能與班別估算，數字為情境模擬

4 條產線、26 道工序，產能瓶頸集中於硫化



一顆胎由四種半成品組成（四條線各做一種）

A　胎體／胎面膠
內部胎體＋最外圈紋路

B　胎側膠
兩側甜甜圈膠片，單側 3–5 片

C　鋼絲圈
胎側膠內緣，固定輪圈

D　尼龍布
包住鋼絲圈，加壓黏合

硫化為什麼是瓶頸

硫化＝全廠瓶頸

小胎 24／中胎 28／大胎 34 小時

120–130°C、油壓表 20 kgf/cm²〔實廠參數〕

全廠 11 台，一台一次一顆

小 小 小 小 小 小 小 中大 中大 中大 中大

中、大胎共用同樣 4 台：排入中胎，大胎即須等待

組合順序：D 包住 C → 配上 B → 與 A 在油壓機貼合 → 硫化；依工廠說明整理。硫化時數為實廠低溫長時硫化參數

04　場景落地｜三個痛點

硫化機日夜不停，缺工問題嚴重：異常發現晚、處置來不及、機台排不滿

01 看不見

2 小時巡檢一次

28 台機台靠人工巡檢；中小廠多無 MES，現成方案導入動輒百萬

02 來不及

整批 報廢風險

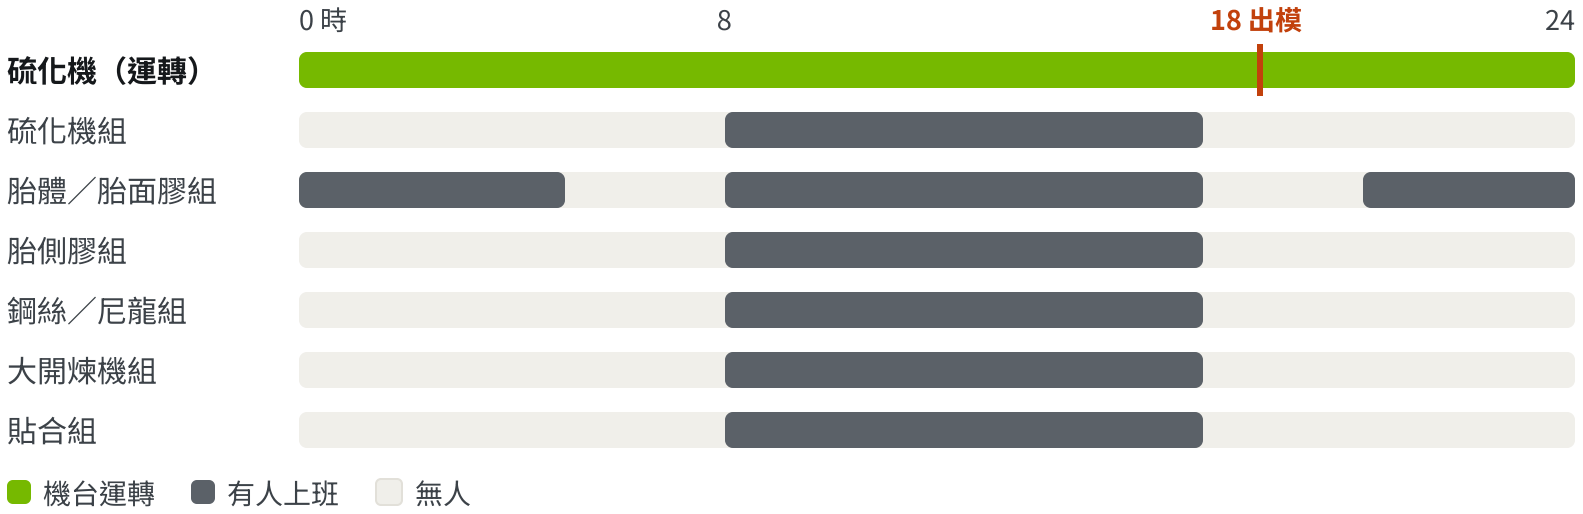
預熱過熱會提早硬化、硫化降溫不能開模；巡檢發現時已過頭

03 排不好

14 小時閒置

大胎 18:00 出模，隔日 8:00 才有人換模；產線時而空機、時而堆料

根源：硫化機 24 小時運轉，各組多半只上早班



中、大胎各 100 條

13.3 週

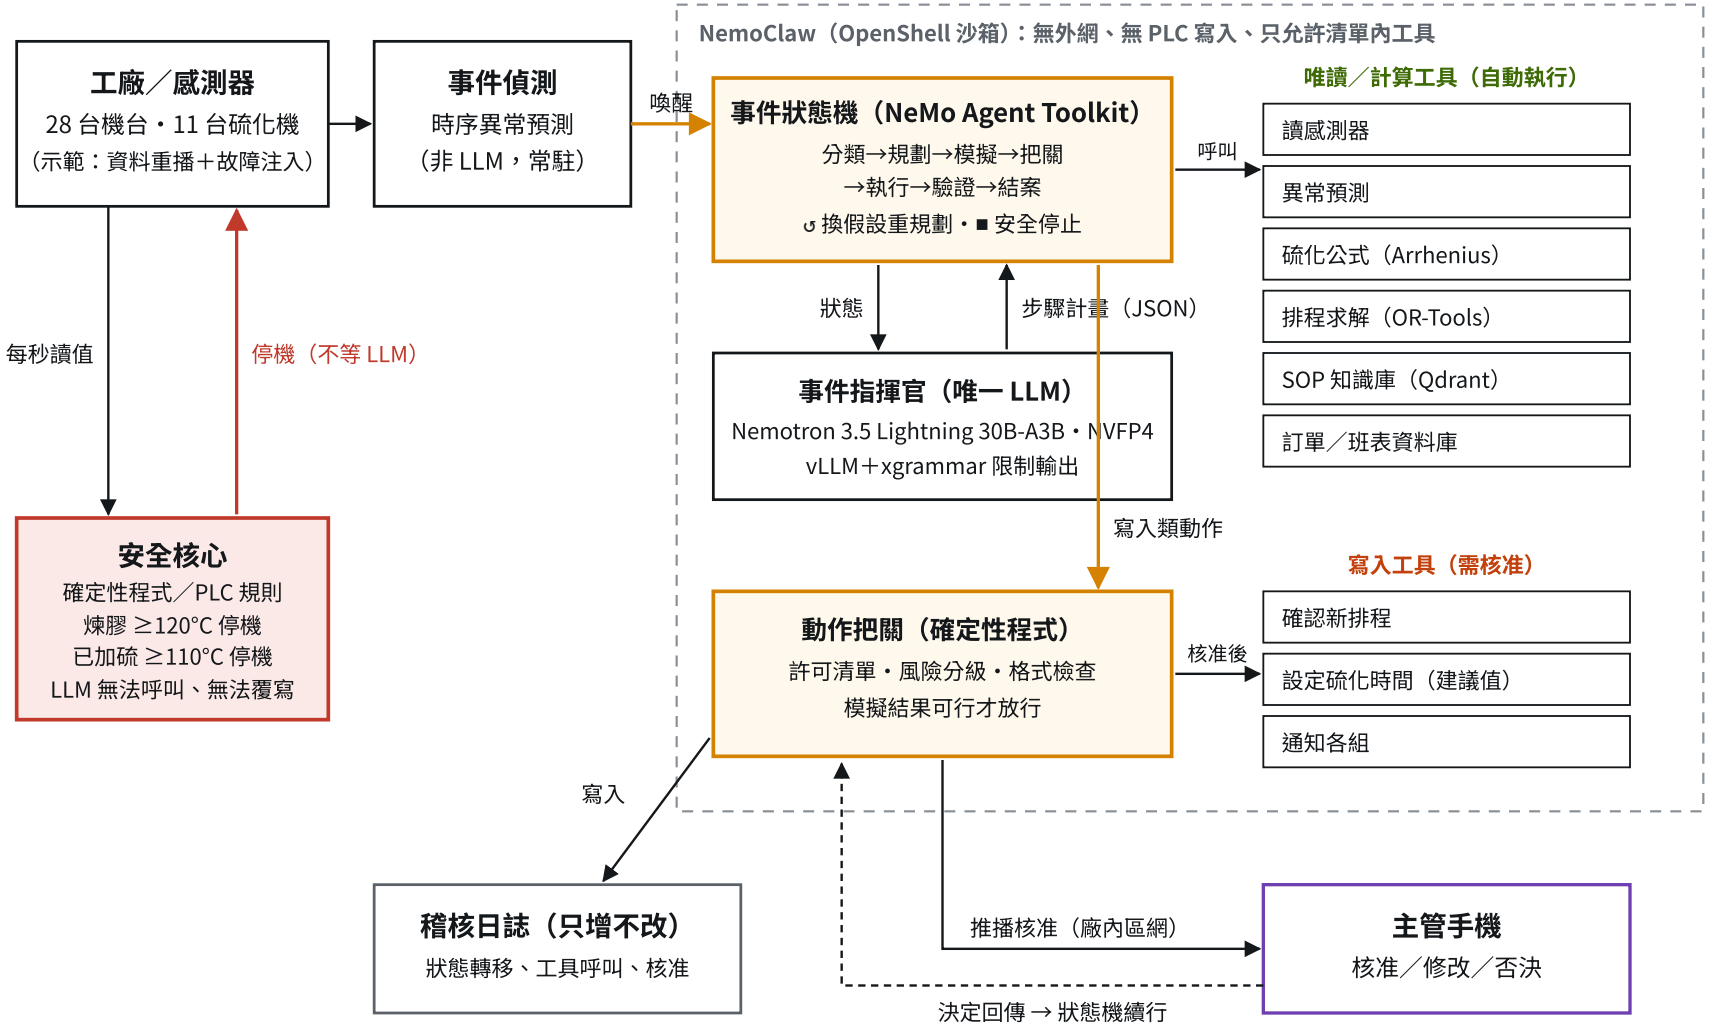
擠在同樣 4 台硫化機上

貼合組工時

87% ↔ 35%

前段滿載、後段閒置

系統架構：一個 Agent 負責判斷，其餘交給程式，LLM 只在事件發生時醒來



琥珀色＝控制路徑

事件偵測喚醒狀態機；LLM 只回傳計畫；寫入動作一定經過動作把關與主管核准

紅色＝安全路徑

由安全核心直接回到機台，不經沙箱、不經 LLM

職責分工：

監控：事件偵測程式
排程：求解器
投料／人力：資料查詢＋求解約束
安全：安全核心
判斷與規劃：唯一 LLM

以硫化機為中心：先排出模時刻，再往前推投料與人力

優化前提（假設可行）：硫化機組錯班 6:00–15:00、14:00–23:00；胎體／胎面膠組晚班（20:00–5:00）兼做出入模

這套邏輯由誰執行：一個 Agent 規劃，數字交給工具

事件指揮官（LLM）
設定目標、拆成有依賴的步驟
→
排程求解器
OR-Tools 排每台出模時刻 T
→
訂單／班表查詢
由 T 往前推投料；人力衝突作為求解約束
→
事件偵測
每分鐘比對計畫與實際，異常喚醒指揮官

由入硫化機時間 T 往前推（一顆胎）

步驟	小胎	中胎	大胎
開始貼合	T − 40 分	T − 1 時	T − 1 時 30 分
A 線投料	T − 1 時 40 分	T − 2 時 30 分	T − 3 時 30 分
胎側膠／鋼絲圈	6 片／6 個	8 片／8 個	10 片／10 個

每台硫化機每週可做幾顆（模擬）

做法	小胎	中胎	大胎
現況	6	5	3
只延長班表	6	5.9	4.5
AI 排出模時刻	7	6	4.9

五個優化原則

1. **先排瓶頸：**4 台機只做中大胎，小胎用其餘 7 台
2. **排「出模時刻」，不是盡快重入：**讓每輪出模都落在有人的時段
3. **週末不斷火：**週六晚班送最後一輪，週一清晨出模，免重新預熱
4. **少換模：**中大胎固定機台，每換一次停約 8 小時
5. **平準化＋拉式：**小胎分散生產；每台只備 1 顆胎胚，不堆料

中、大胎各 100 條完成時間

13.3 → 9.3 週

約 −30%；小胎 2.4 → 2.0 週

模擬條件：每週一至六、週六晚班延續至週日 5:00；中、大胎各 2 台，未計換模；出入模作業時間 30 分鐘 〔模擬值〕

Agent 機制如何落實四項作品門檻

01 目標與任務分解

事件指揮官（唯一 LLM）

目標	7 號降溫，大胎不能延誤	**拆解**	S1 硫化公式、S2 查訂單班表
依賴	S3 排程須等 S1、S2 完成	**推進**	S4 確認（需核准）→ S5 通知
狀態機	規劃→模擬→把關→執行→驗證		

02 工具與系統調用

依狀態開放工具

邊緣設備	讀感測器、設定壓縮機	**資料庫**	訂單、班表、操作紀錄
知識庫	SOP 存本機 Qdrant，附來源	**軟體服務**	OR-Tools 排程、硫化公式
API	主管手機推播		

03 狀態與動態調整

驗證狀態（程式比對）

修正計畫	未達預期 → 換假設重新規劃	**重試**	工具失敗重試，再失敗走 SOP
替換工具	求解逾時 → 切換備援求解器	**安全中止**	連續 2 次失敗 → 維持原排程

04 權限與風險控制

動作把關＋安全核心

人工確認	暫停投料、跨組調人需核准	**權限限制**	4 級風險；機台致動無權限
操作紀錄	越權寫入由沙箱攔截並記錄	**失敗回復**	排程保留上一版，一鍵回復
輸出檢核	格式正確且模擬可行才放行		

量化、剪枝、快取、推測解碼：60 GB 壓到約 19 GB，速度提升 2 倍

STEP 1
起點模型
Nemotron 3.5 Lightning 30B-A3B（BF16）
≈ 60 GB

→

STEP 2
MoE 稀疏啟用
每 token 只讀約 3B 參數；速度取決於每 token 讀多少 bytes
啟用 ≈ 1/10

→

STEP 3
NVFP4 量化
官方 NVFP4 檢查點；KV cache 改 FP8
≈ 19 GB

→

STEP 4
前綴快取
系統提示、工具定義、SOP 只算一次
重複事件免重算

→

STEP 5
推測解碼
內建 MTP／DSpark 草稿模型，一次預測多個 token
95–108 tok/s

逐步最佳化實測（公開 DGX Spark 數據）

設定（DGX Spark 單流）	權重	decode tok/s	相對
Nemotron 3 Nano，FP8	≈ 30 GB	47.6	—
Nemotron 3 Nano，NVFP4	≈ 18 GB	74.75	FP8 的 1.6 倍
Lightning，NVFP4＋推測解碼（採用）	≈ 19 GB	95–108	FP8 的 2 倍以上

瓶頸是頻寬，不是算力
273 GB/s ÷ 每 token 讀 1.7 GB ≈ 160 tok/s 上限；在 Spark 上 NVFP4 比 FP8 快約 1.5 倍

準確度代價
NVFP4 僅掉 0.9–2.9 分；agent 任務 PinchBench 85.4（前代 66.1）；廠區任務準確率〔決賽實測〕

剪枝
MoE 本身是結構化稀疏（每 token 只走少數專家）；下放 Jetson 時改用 NVIDIA 以 Nemotron Elastic 剪枝＋蒸餾的 Nano 4B（9B → 3.97B）

速度來源：NVIDIA 開發者論壇、Hugging Face 模型卡之 DGX Spark 公開實測；決賽以相同設定重測

資料不出廠、斷網照跑：單台 DGX Spark 承載全系統

保密　配方不出廠；51% 企業擔憂雲端外洩、72% 需地端

隔離　控制網路依 IEC 62443 分區，本來就不連外

夜班　無人巡檢時本地即時告警，不必等到早上

① 記憶體預算

36–50 GB ／128 GB



模型 NVFP4	19 GB	草稿模型	2 GB
KV＋狀態	4 GB	vLLM／CUDA	5 GB
DGX OS	10 GB	Qdrant	3 GB
排程＋應用	6 GB		

不到四成 → 全部常駐，事件時不用等載入

② 延遲預算

< 0.2 秒　安全路徑：規則直接處置，不經 LLM

≤ 2 秒　第一張告警卡（LLM 輸出 ≤ 100 tokens）

≈ 22 秒　完整事件：4 次工具回合＋求解＋診斷

LLM 平時休眠，每分鐘監控交給時序模型與規則

③ 離線與弱網：三層斷網

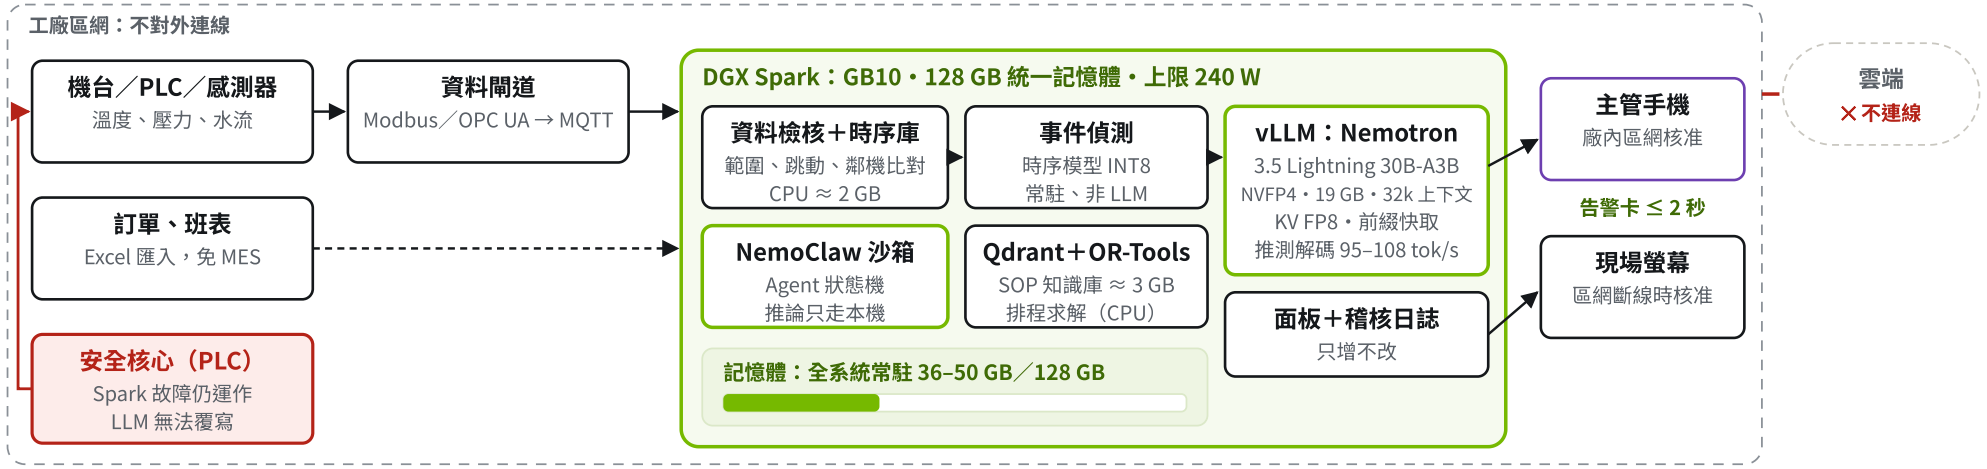
弱網	Agent 不受影響，只延後同步與推播
斷外網	主管手機經廠內區網核准
區網斷	現場觸控螢幕＋警示燈核准

全部在本機：推論只走本機 Nemotron
驗證：拔網路線 → 2 秒內告警、對外連線 0 次

調查：台灣人工智慧實驗室 2026（n=562）；量測：NVFP4・vLLM・batch 1・上下文最長 32k（含與主管對話），NeMo Agent Toolkit profiler **〔決賽實測〕**

一台 Spark 全在廠內：部署架構、24 小時運轉與驗證方法

① 部署架構：一台 Spark、全在廠內



② 穩定運轉、安全與成本

壞資料	讀值異常 → 不叫醒 AI	**開機自啟**	容器自啟，模型預先載入
自動重啟	watchdog 異常即重啟	**Spark 故障**	安全核心仍在 PLC 運作
離線更新	USB／區網更新，一鍵回滾	**實體安全**	磁碟加密、網路白名單
功耗	上限 240 W，峰值 233 W	**成本**	US$4,699，無雲端費

③ 驗證方法（補充 p.08–09 的速度、記憶體、斷網目標）

首字延遲	單流，32k 對話、前綴快取	**≤ 0.5 秒**
同時 3 件異常	vLLM 批次處理	**每件 ≤ 4 秒**
壓縮後準確率	廠區題庫，NVFP4 對 FP8	**差距 ≤ 3 分**
每瓦效能	插座電表量整機功耗	**tokens／W 公布**

對照組：以 FP8、無快取、無推測解碼再跑一次，列出各項最佳化貢獻

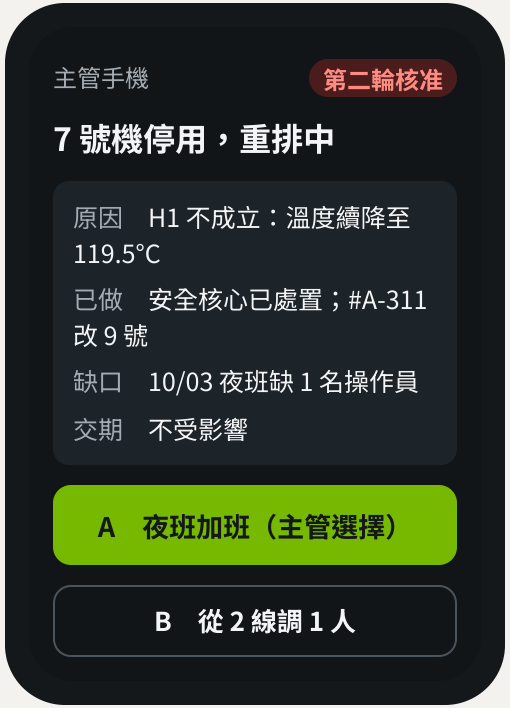
目標值 以 NeMo Agent Toolkit profiler 記錄；價格為 NVIDIA 2026 官方售價、功耗為公開評測

11　場景落地｜情境：硫化機溫度過低

硫化機 7 號 128 → 122°C：先延長硫化，驗證失敗就換假設

[工具] 工具調用　[人工] 人機協作　右欄 = 對應評分項目

02:14:00	事件偵測	[工具] 7 號 128 → 122°C，預測穩定在 122±1°C → 喚醒指揮官	工具調用
02:14:01	安全核心	仍在 120–130°C，不停機（低於 120°C 直接處置，不等 AI）	安全路徑
02:14:03	指揮官	[工具] 讀 30 分鐘溫度、[工具] 查 SOP → **假設 H1：蒸汽壓不足，溫度會穩定**	自主決策
02:14:09	指揮官	拆步驟：S1 硫化公式、S2 訂單班表 → S3 排程（依賴 S1、S2）→ S4 確認（需核准）→ S5 通知；預期：30 分內 ≥ 121°C	任務分解
02:14:11	工具	[工具] S1：122°C 總需 36.5 h（+8.5 h）　[工具] S2：下一模 #A-311 交期 3 天後，夜班缺 1 人	工具調用
02:14:25	求解器	[工具] S3：#A-311 移到 9 號機、夜班從 2 線調 1 人，**交期全部滿足**	工具調用
02:16:40	主管	動作把關確認可行 → [人工] 主管核准；寫入稽核日誌	權限＋人工
02:31:00	驗證（程式）	比對預期：溫度降到 **119.5°C** → **H1 不成立**；安全核心已依規則處置	動態調整
02:31:04	指揮官	**推翻 H1 → H2：持續洩壓或感測器漂移**；[工具] 對照 6、8 號同管線 → [工具] SOP「硫化中斷處置」→ 7 號停用重排	自主決策
02:31:30	主管	[人工] 否決跨組調人，**改選夜班加班**；決定與理由寫入紀錄	人機協作



一般排程：異常後靠人工改表。戰情室：AI 算出連鎖影響、提出方案，人選擇；物理公式與排程交給工具，數值由公式與求解器計算，不由 AI 推測

示意情境：中胎 128°C 硫化 28 小時、已進行 10 小時；活化能 85 kJ/mol 為假設值，需以工廠資料校正 〔模擬值〕；等效硫化參考 US3980743

一台 DGX Spark，資料不出廠、斷網照跑
讓傳統實心胎廠交期縮短三成

場景落地

−30% 交期

中、大胎各 100 條
13.3 週→ 9.3 週

Agent 架構

1 分鐘

異常發現從 2 小時縮到 1 分鐘
1 個 LLM，依狀態開放工具

邊緣部署

108 tok/s

單台 DGX Spark 推論速度
NVFP4＋MoE＋推測解碼

✓ **已完成**　系統架構、Agent 迴圈原型、硫化與排程計算
○ **決賽前**　模擬資料、OR-Tools 與 Qdrant 接入、Spark 實測與拔網示範

既有程式碼揭露　本隊無沿用既有專案程式碼；使用開源套件 vLLM、OR-Tools、Qdrant、NeMo Agent Toolkit、NemoClaw